



**POLITECHNIKA
RZESZOWSKA**
im. IGNACEGO ŁUKASIEWICZA

Projektowanie modeli łączenia źródeł danych

Draguła Bartłomiej, Dereń Adrian

166643, 166724

Inżynieria i Analiza Danych

Grupa projektowa 1.

09.02.2023

Spis treści

Wstęp teoretyczny	3
Opis danych.....	3
Eliminacja Quasi-stałych.....	4
Metoda analizy macierzy współczynników korelacji	5
Metoda Hellwiga	6
Estymacja parametrów	7
Regresja	8
Składniki resztowe	9
Istotność statystyczna	9
Weryfikacja modelu	10
Wyrazistość modelu	10
Test symetrii	11
Variance Inflation Factor	12
Test Goldfelda – Quandta.....	12
Test Shapiro Wilka.....	13
Test Jarque – Bera	13
Badanie koincydencji	14
Test autokorelacji reszt.....	14

Wstęp teoretyczny

Analiza statystyczna jest ważnym narzędziem w procesie podejmowania decyzji i formułowania wniosków na podstawie danych. W szczególności, analiza rozkładów normalnych jest szeroko stosowana w różnych dziedzinach, w tym w ekonomii, medycynie i inżynierii, w celu opisywania i porównywania danych. W projekcie będziemy analizować dane z Głównego Urzędu Statystycznego (GUS) dotyczące przeciętnych cen niektórych produktów z nabiału. Celem projektu jest zbadanie, czy ceny te można opisać za pomocą rozkładu normalnego oraz porównanie tych cen z cenami innych produktów. Aby wykonać tę analizę, będziemy wykorzystywać różne narzędzia statystyczne, w tym testy normalności, takie jak test Shapiro-Wilka, test Goldfelda-Quandta, test Jarqua-Bera oraz wizualizacje danych. Oczekujemy, że wyniki projektu pozwolą nam na uzyskanie lepszego zrozumienia przeciętnych cen produktów z nabiału i pomogą w formułowaniu wniosków dotyczących trendów i zmienności tych cen. W dalszej części tego wprowadzenia omówimy szczegółowo metodologię projektu i założenia dotyczące oczekiwanych wyników.

Opis danych

W ramach projektu z Projektowania Modeli Łączenia źródeł danych, zdecydowaliśmy się wybrać dane dotyczące przeciętnych cen producentów niektórych wyrobów spożywczych na rynku krajowym. Produkty, które wybraliśmy to produkty będące przykładami kategorii tłuszczy oraz nabiałów. Dane, z których korzystamy to ceny roczne poczynając od roku 2010, na 2021 kończąc. Skupiliśmy się na dziesięciu różnych produktach:

- Cena słoniny - za 1 kg,
- Cena smalcu wieprzowego jadalnego paczkowanego w kostkach 250g – za 1 kg,
- Cena oleju jadalnego rafinowanego rzepakowego konfekcjonowanego – za 1 l,
- Cena masła świeżego o zawartości tłuszcza ok. 82,5% - za 1kg,
- Cena mleko krowiego o zawartości tłuszcza 1,5-2%, w opakowaniu z folii - za 1l,
- Cena jaj kurzych świeżych - za 1szt.,
- Cena mleka krowiego o zawartości tłuszcza 3-3,5% (przedłużony okres trwałości, UHT), w opakowaniu kartonowym - za 1l,
- Cena śmietany o zawartości tłuszcza 18% - za 1l,
- Cena sera twarogowego półtłustego - za 1kg,
- Cena sera dojrzewającego "Gouda" - za 1kg.

Jako kolumnę Y wybraliśmy natomiast wskaźnik cen towarów i usług konsumpcyjnych, czyli oczywiście wskaźnik inflacji.

Produkt	Zmiana cen produktu na przestrzeni lat											
	2010 [zł]	2011 [zł]	2012 [zł]	2013 [zł]	2014 [zł]	2015 [zł]	2016 [zł]	2017 [zł]	2018 [zł]	2019 [zł]	2020 [zł]	2021 [zł]
Wskaźnik cen towarów i usług konsumpcyjnych (pot. inflacja)	102,6	104,3	103,7	100,9	100,0	99,1	99,4	102,0	101,6	102,3	103,4	105,1
słonina - za 1kg	3,86	4,32	5,80	5,72	5,17	4,45	4,36	4,46	4,50	5,17	6,17	6,02
smalc wieprzowy jadalny paczkowany w kostkach 250g - za 1kg	4,56	5,18	6,50	6,35	6,15	5,72	5,58	6,00	6,11	6,56	7,78	7,60
olej jadalny rafinowany rzepakowy konfekcjonowany - za 1l	4,23	5,29	5,50	5,21	5,24	5,46	4,84	4,97	4,50	4,43	4,66	5,49
masto świeże o zawartości tłuszcza ok. 82,5% - za 1kg	15,05	16,91	15,95	17,23	17,05	15,15	16,19	22,85	23,89	21,00	19,17	22,20
mleko krowie o zawartości tłuszcza 1,5-2%, w opakowaniu z folii	1,67	1,67	1,68	1,70	1,81	1,74	1,66	1,71	1,75	1,78	1,85	1,96
jaja kurze świeże - za 1szt.	0,27	0,26	0,41	0,32	0,29	0,3	0,26	0,35	0,32	0,3	0,32	0,37
mleko krowie o zawartości tłuszcza 3-3,5% (przedłużony okres trwałości)	1,80	1,98	2,04	2,13	2,15	1,89	1,85	2,05	2,05	2,07	2,25	2,43
śmietana o zawartości tłuszcza 18% - za 1l	5,47	5,56	5,59	5,70	5,75	5,57	5,52	6,09	6,64	6,86	7,04	7,47
ser twarogowy półtłusty - za 1kg	8,66	8,97	9,10	9,23	9,58	9,22	9,01	9,16	9,22	9,27	9,49	9,87
ser dojrzewający "Gouda" - za 1kg	12,84	14,01	14,19	15,71	14,80	12,00	12,52	14,86	13,80	14,49	15,05	16,59

Eliminacja Quasi-stałych

Eliminacja quasi-stałych to metoda stosowana w modelowaniu i analizie danych, której celem jest usunięcie zmiennych, które są bardzo słabo związane ze zmienną objaśnianą. Zmienne te nazywane są quasi-stalymi, ponieważ ich wartości są prawie stałe w kontekście innych zmiennych. Eliminacja quasi-stałych jest używana, ponieważ takie zmienne mogą mieć negatywny wpływ na jakość modelu i wyników analizy. Mogą powodować nadmierną złożoność modelu i zaburzenie interpretacji wyników, co może prowadzić do błędnych wniosków. Metoda eliminacji quasi-stałych może być wykonywana na kilka sposobów, w tym za pomocą analizy korelacji, testów statystycznych i wizualizacji danych. Po usunięciu quasi-stałych, pozostałe zmienne są bardziej związane ze zmienną objaśniającą i pozwalają na bardziej skuteczne i jasne modelowanie oraz analizę danych.

ELIMINACJA QUASI-STAŁYCH											
	Y	X1	X2	X3	X4	X5	X6	X7	X8	X9	X10
2010	102,6	3,86	4,56	4,23	15,05	1,67	0,27	1,80	5,47	8,66	12,84
2011	104,3	4,32	5,18	5,29	16,91	1,67	0,26	1,98	5,56	8,97	14,01
2012	103,7	5,80	6,50	5,50	15,95	1,68	0,41	2,04	5,59	9,10	14,19
2013	100,9	5,72	6,35	5,21	17,23	1,70	0,32	2,13	5,70	9,23	15,71
2014	100,0	5,17	6,15	5,24	17,05	1,81	0,29	2,15	5,75	9,58	14,80
2015	99,1	4,45	5,72	5,46	15,15	1,74	0,3	1,89	5,57	9,22	12,00
2016	99,4	4,36	5,58	4,84	16,19	1,66	0,26	1,85	5,52	9,01	12,52
2017	102,0	4,46	6,00	4,97	22,85	1,71	0,35	2,05	6,09	9,16	14,86
2018	101,6	4,50	6,11	4,50	23,89	1,75	0,32	2,05	6,64	9,22	13,80
2019	102,3	5,17	6,56	4,43	21,00	1,78	0,3	2,07	6,86	9,27	14,49
2020	103,4	6,17	7,78	4,66	19,17	1,85	0,32	2,25	7,04	9,49	15,05
2021	105,1	6,02	7,60	5,49	22,20	1,96	0,37	2,43	7,47	9,87	16,59
WSP. ZM.	-	14,42%	13,07%	8,45%	16,13%	3,47%	13,48%	6,36%	9,36%	2,59%	7,83%
WAR KRYT	10%	14,88%	14,09%	8,58%	16,28%	4,91%	13,78%	8,10%	11,07%	3,23%	8,90%

Jak widać, w naszym przypadku po eliminacji Quasi – stałych oraz ustaleniu wartości krytycznej jako 10%, z dziesięciu zmiennych pozostaje nam dokładnie pięć. Są to te, których współczynnik zmienności był większy od wspomnianych 10%.

Metoda analizy macierzy współczynników korelacji

Analiza macierzy współczynników korelacji to jedna z metod stosowanych do identyfikacji wzajemnych powiązań między zmiennymi w danych. Polega ona na określeniu współczynników korelacji między każdą parą zmiennych, a następnie na przedstawieniu tych wartości w formie macierzy. Współczynnik korelacji między dwoma zmiennymi mówi o stopniu, w jakim ich wartości są skorelowane. Wartość współczynnika korelacji może wynosić od -1 do 1. Wartość -1 oznacza ujemną korelację, co oznacza, że wzrost wartości jednej zmiennej powoduje spadek wartości drugiej. Wartość 1 oznacza dodatnią korelację, co oznacza, że wzrost wartości jednej zmiennej powoduje wzrost wartości drugiej. Wartość 0 oznacza brak korelacji między zmiennymi.

Metoda analizy macierzy współczynników korelacji						
	<i>Y</i>	<i>X1</i>	<i>X2</i>	<i>X4</i>	<i>X6</i>	<i>X8</i>
<i>Y</i>	1	0,382461684	0,3548139	0,313465	0,42873264	0,486797
<i>X1</i>	0,3824617	1	0,9081276	0,188092	0,6352101	0,55614
<i>X2</i>	0,3548139	0,908127586	1	0,482989	0,60499182	0,798629
<i>X4</i>	0,3134648	0,188092197	0,482989	1	0,35469661	0,772636
<i>X6</i>	0,4287326	0,635210104	0,6049918	0,354697	1	0,362527
<i>X8</i>	0,4867967	0,556140496	0,7986294	0,772636	0,36252664	1

W naszym przypadku, wszystkie uzyskane wartości są wartościami dodatnimi. Wynika z tego, że przy jednoczesnym wzroście cen jednego produktu, zwiększa się również cena drugiego. Jest tak dlatego, że jak oczywiście wiadomo, ceny produktów spożywczych wzrastały na przestrzeni lat, co jest oczywiście rezultatem między innymi postępującej inflacji.

Metoda Hellwiga

Metoda Hellwiga może być wykorzystywana w połączeniu z kombinacjami zmiennych objaśniających w celu lepszego zrozumienia zależności między zmiennymi i stopnia normalności ich rozkładów. W tym przypadku, po dodaniu kombinacji zmiennych objaśniających, możemy wykonać test Hellwiga i porównać wyniki z wynikami bez uwzględnienia tych zmiennych. Jeśli dodanie kombinacji zmiennych objaśniających poprawiło stopień normalności rozkładu, to możemy uznać, że te zmienne mają istotny wpływ na nasze dane i warto je uwzględnić w dalszej analizie. W przypadku, gdy wyniki nie uległy znaczącej poprawie, możemy uznać, że kombinacja ta nie ma istotnego wpływu na nasze dane i nie jest konieczna do uwzględnienia. W ten sposób, metoda Hellwiga w połączeniu z kombinacjami zmiennych objaśniających pozwala na lepsze zrozumienie zależności między zmiennymi i stopnia normalności ich rozkładów, co jest ważne przy wyborze odpowiedniego modelu statystycznego i dokonywaniu innych obliczeń.

Metoda Hellwiga						
Kombinacja	Indywidualne pojemności nośników informacji h			Integralne pojemności nośników informacji H		
1 X1	0,1462769					0,14627694
2 X2		0,125892921				0,125892921
3 X4			0,09826			0,098260164
4 X6				0,183812		0,183811675
5 X8					0,23697107	0,236971067
6 X1X2	0,0766599	0,065977203				0,14263714
7 X1X4	0,1231192		0,082704			0,205823339
8 X1X6	0,0894545			0,112409		0,201863121
9 X1X8	0,0939998				0,15228128	0,246281108
10 X2X4		0,084891336	0,066258			0,151149522
11 X2X6		0,078438357		0,114525		0,192963349
12 X2X8		0,069993809			0,13175091	0,201744723
13 X4X6			0,072533	0,135685		0,208217719
14 X4X8			0,055432		0,1336829	0,189114576
15 X6X8				0,134905	0,17392032	0,308825332
16 X1X2X4	0,0697813	0,052650264	0,0588			0,181231914
17 X1X2X6	0,0575138	0,050094286		0,082051		0,189659443
18 X1X2X8	0,0593592	0,046510611			0,10063449	0,206504284
19 X1X4X6	0,0802264		0,06369	0,092372		0,236288348
20 X1X4X8	0,0838632		0,050114		0,10175777	0,235735102
21 X1X6X8	0,066752			0,09201	0,12350817	0,282270085
22 X2X4X6		0,060294097	0,05347	0,093796		0,207559991
23 X2X4X8		0,055177027	0,043562		0,09216128	0,19090059
24 X2X6X8		0,052376357		0,093423	0,10965014	0,2554496
25 X4X6X8			0,0461894	0,10704	0,11098504	0,264214481
26 X1X2X4X6	0,0535532	0,063069179	0,0485049	0,070836		0,235963117
27 X1X2X4X8	0,0551497	0,039468008	0,0680606		0,1113897	0,274067988
28 X1X2X6X8	0,0471941	0,038014031		0,070623	0,08720839	0,243039162
29 X1X4X6X8	0,0614753		0,0424372	0,078137	0,08805069	0,270100024
30 X2X4X6X8		0,043612719	0,0376429	0,079154	0,08077297	0,241182226
31 X1X2X4X6	0,0444939	0,033175657	0,0351128	0,062153	0,06790134	0,242836346

Estymacja parametrów

Estymacja parametrów to proces określania wartości nieznanych parametrów modelu na podstawie dostępnych danych. W statystyce, estymacja parametrów polega na doborze takich wartości parametrów, które najlepiej pasują do danych i pozwala na opisanie ich rozkładu. Po dokonaniu estymacji parametrów, ważne jest wyznaczenie ich błędów i przeprowadzenie testów statystycznych, aby ocenić ich jakość i stopień ufności w nasze wyniki. Wnioski z estymacji parametrów pozwalają na lepsze zrozumienie i opisanie danych. Wiedza o estymowanych parametrach pozwala na lepsze prognozowanie i podejmowanie decyzji opartych na danych.

Estymacja parametrów								
	X1	X2	X4	X6	X8			
2010	102,6	3,86	4,56	15,05	0,27	5,47	1,00	
2011	104,3	4,32	5,18	16,91	0,26	5,56	1,00	
2012	103,7	5,80	6,50	15,85	0,41	5,59	1,00	
2013	100,9	5,72	6,35	17,23	0,32	5,70	1,00	
2014	100,0	5,17	6,15	17,05	0,29	5,75	1,00	
2015	99,1	4,45	5,72	15,15	0,3	5,57	1,00	
2016	99,4	4,36	5,58	16,19	0,26	5,52	1,00	
2017	102,0	4,46	6,00	22,85	0,35	6,09	1,00	
2018	101,6	4,50	6,11	23,89	0,32	6,64	1,00	
2019	102,3	5,17	6,56	21,00	0,3	6,86	1,00	
2020	103,4	6,17	7,78	19,17	0,32	7,04	1,0	
2021	105,1	6,02	7,60	22,20	0,37	7,47	1,00	

	X1	X2	X4	X6	X8			
1,00	3,86	4,56	15,05	0,27	5,47			
1,00	4,32	5,18	16,91	0,26	5,56			
1,00	5,80	6,50	15,95	0,41	5,59			
1,00	5,72	6,35	17,23	0,32	5,70			
1,00	5,17	6,15	17,05	0,29	5,75			
1,00	4,45	5,72	15,15	0,3	5,57			
1,00	4,36	5,58	16,19	0,26	5,52			
1,00	4,46	6,00	22,85	0,35	6,09			
1,00	4,50	6,11	23,89	0,32	6,64			
1,00	5,17	6,56	21,00	0,3	6,86			
1,0	6,17	7,78	19,17	0,32	7,04			
1,00	6,02	7,60	22,20	0,37	7,47			

	XT							
1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00
3,86	4,32	5,80	5,72	5,17	4,45	4,36	4,46	5,17
4,56	5,18	6,50	6,35	6,15	5,72	5,58	6,00	6,11
15,05	16,91	15,85	17,23	17,05	15,15	16,19	22,85	23,89
0,27	0,26	0,41	0,32	0,29	0,3	0,26	0,35	0,32
5,47	5,56	5,59	5,70	5,75	5,57	5,52	6,09	6,64
1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00	1,00

	XTX							
12	60	74,09	222,64	3,77	73,26			
60,0	306,6	377,5	118,273	19,0955	369,6544			
74,09	377,50	466,53	1389,854	23,5501	457,9537			
222,64	1 118,27	1 389,85	4240,251	70,5028	1378,1433			
3,77	19,10	23,55	70,5028	1,2069	23,1431			
73,26	369,6544	457,9537	1378,143	23,1431	452,7302			

(XTX) ⁻¹	XTY	a
11,869988	-1,60296	2,530089715
-1,602969	2,054604	-1,863297527
2,5300897	-1,8633	2,294086149
-0,0541	-0,439037	-1,02147104
0,1008148	0,137624	-0,054095983
0,040511	-1,28444	-0,14470829
-14,145798	-4,847356	-0,439037038
-1,02844	102,138341	4,600481079
-2,7549204	0,295454	-1,021471042
-0,14471	4,60048108	1,445353967
	1224,4	-1737,405

PODSUMOWANIE - WYŚCIE

Statystyki regresji

$$\hat{Y} = 8962,186 x_1 - 72498,6 x_2 + 49012,13 x_4 - 7427,51 x_6 + 636108,5 x_8 - 1737,41$$

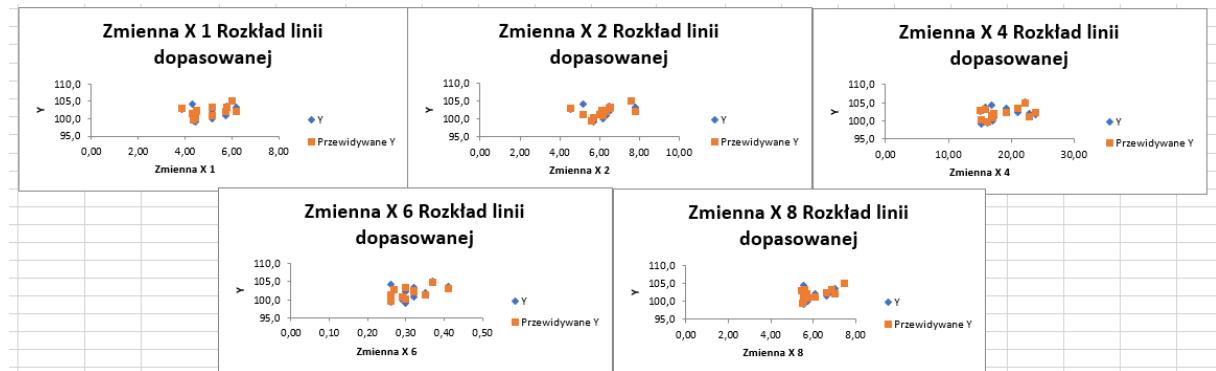
Wartościami, które na ten moment przydadzą nam się najbardziej, są wartości a, z których skorzystamy w jednym z kolejnych kroków. Ponadto korzystając z tych wartości, jesteśmy także w stanie wyprowadzić wzór na model oszacowany, który znajduje się w prawym dolnym rogu powyższego obrazu.

Regresja

Korzystając z wbudowanej funkcji w MS Excel przeanalizowaliśmy danę pod kątem regresji. Po zaznaczeniu obszarów zawierających kolumnę Y oraz kolumny zawierające dane zmiennych objaśniających X1, X2, X4, X6 oraz X8, otrzymaliśmy pokazane poniżej podsumowanie.

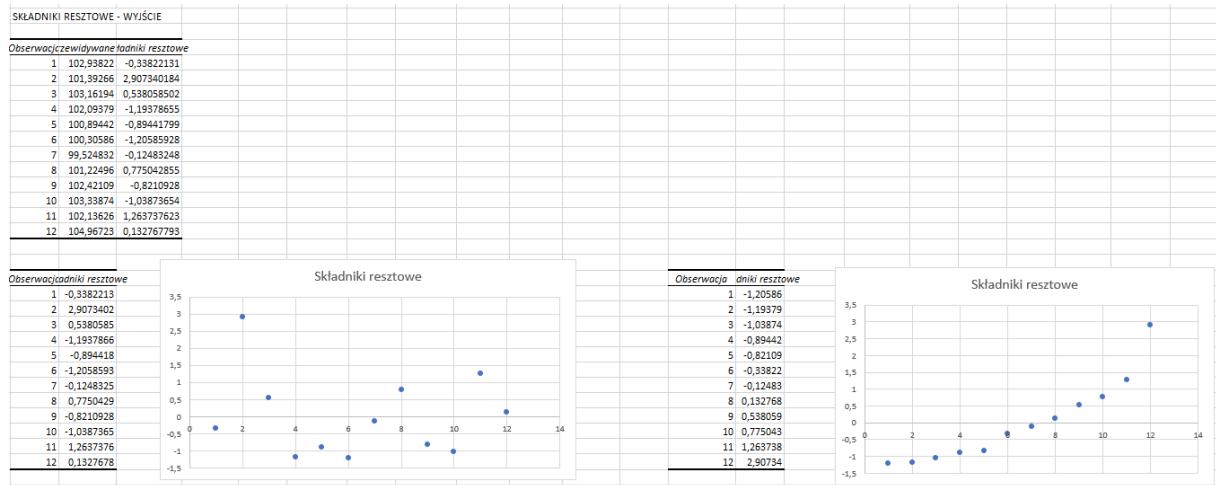
PODSUMOWANIE - WYJŚCIE						
Statystyki regresji						
Wielokrotny R	0,7709559					
R kwadra	0,594373					
Dopasowanie	0,2563505					
Błąd standaryzowany	1,6593089					
Obserwacji	12					
ANALIZA WARIANCJI						
	df	SS	MS	F	Istotność F	
Regresja	5	24,20683101	4,8413662	1,758383	0,25538738	
Resztkowa	6	16,51983566	2,7533059			
Razem	11	40,72666667				
Współczynnik i jego standard						
	t Stat	Wartość-p	Dolne 95%	Górne 95%	Dolne 95,0%	Górne 95,0%
Przecięcie	85,494648	5,716649709	14,955376	5,63E-06	71,5065105	99,48279
Zmienna X1	3,2464271	2,378435106	1,3649425	0,221237	-2,5733939	9,066248
Zmienna X2	-4,8020958	2,513229203	-1,9107274	0,104602	-10,951746	1,347555
Zmienna X4	-0,1295869	0,333974234	-0,3880146	0,711398	-0,9467924	0,6876186
Zmienna X6	20,342141	16,76954236	1,2130409	0,2707	-20,691451	61,37573
Zmienna X8	4,2537158	1,994868834	2,1323286	0,076961	-0,6275524	9,134984

Ponadto wygenerowaliśmy również rozkład linii dopasowanych dla każdego X.



Składniki resztowe

Składniki resztowe są to różnice pomiędzy wartościami faktycznymi a wartościami przewidywanymi przez model. Są one używane do oceny jakości modelu i jego zgodności z danymi.



Istotność statystyczna

Korzystając z wygenerowanej wcześniej tabeli, zawierającej statystyki regresji oraz bazując na naszych danych sprawdziliśmy również istotność statystyczną. W naszym przypadku k jest równe 5 jako, że jest to ilość zmiennych pozostała po eliminacji Quasi – stałych. N oznacza natomiast kolumny zawierające kolejno poszczególne lata.

ISTOTNOŚĆ STATYSTYCZNA F			
<i>Statystyki regresji</i>	<i>k</i>	5	
<i>Wielokrotnie</i>	<i>n</i>	12	
<i>R kwadra</i>	<i>alfa</i>	0,05	
<i>Dopasow</i>	<i>s1 = k</i>	5	
<i>Błąd stan</i>	<i>s2 = n-k-1</i>	6	
<i>Obserwac</i>	<i>Femp</i>	1,758382941	<i>F</i>
12			0,202008

Weryfikacja modelu

SSE, SST i SSR to skróty od odpowiednio resztowej sumy kwadratów, całkowej sumy kwadratów odchyleń i regresyjnej sumy kwadratów. Są to używane w statystyce do weryfikacji modeli regresji.

SSE (sum of squared errors) to suma kwadratów różnic między wartościami prognozowanymi przez model i rzeczywistymi wartościami.

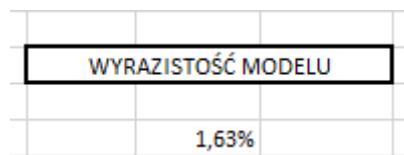
SST (sum of squared totals) to suma kwadratów różnic między rzeczywistymi wartościami a średnią wartością danych. Jest to miernik zmienności danych.

SSR (sum of squared residuals) to część zmienności wyjaśniona przez model liniowy. Im większe SSR, tym lepsze pasowanie modelu do danych.

WERYFIKACJA MODELU										
t	y	x1	x2	x4	x6	x8	\hat{y}^*	$e(y - \hat{y}^*)$		a
1	102,6	3,86	4,56	15,05	0,27	5,47	3074,79101	-2 972,2	8 833 919,4	0,3
2	104,3	4,32	5,18	16,91	0,26	5,56	-20219,639	20 323,9	413 062 498,8	5,1
3	103,7	5,80	6,50	15,95	0,41	5,59	39673,0621	-39 569,4	1 565 734 417,2	2,8
4	100,9	5,72	6,35	17,23	0,32	5,70	-28826,963	28 927,9	836 821 245,1	1,3
5	100,0	5,17	6,15	17,05	0,29	5,75	-16588,354	16 688,4	278 501 143,4	4,1
6	99,1	4,45	5,72	15,15	0,3	5,57	35321,4755	-35 222,4	1 240 615 739,0	8,6
7	99,4	4,36	5,58	16,19	0,26	5,52	1902,57106	-1 803,2	3 251 425,9	6,9
8	102,0	4,46	6,00	22,85	0,35	6,09	22030,0738	-21 928,1	480 840 420,2	0,0
9	101,6	4,50	6,11	23,89	0,32	6,64	-3241,969	3 343,6	11 179 453,7	0,2
10	102,3	5,17	6,56	21,00	0,3	6,86	-21399,459	21 501,8	462 325 646,4	0,1
11	103,4	6,17	7,78	19,17	0,32	7,04	-8101,4518	8 204,9	67 319 592,9	1,9
12	105,1	6,02	7,60	22,20	0,37	7,47	2504,1518	-2 399,1	5 755 449,5	9,4
									5 374 240 951,5	40,7
									sse	sst
										ssr

Wyrazistość modelu

Obliczyliśmy również wyrazistość modelu poprzez podzielenie błędu standardowego przez średnią z wartości kolumny Y.



Test symetrii

Test symetrii na podstawie liczby reszt dodatnich polega na ocenie, czy rozkład reszt jest symetryczny. W tym teście, liczba reszt dodatnich jest porównywana z liczbą reszt ujemnych, aby ustalić, czy model jest w stanie wyjaśniać symetrię danych. Jeśli liczba reszt dodatnich jest zbliżona do liczby reszt ujemnych, można uznać, że model jest w stanie wyjaśniać symetrię danych i jest to pozytywny wynik testu. Test symetrii na podstawie liczby reszt dodatnich jest ważny, ponieważ pomaga ocenić, czy model jest w stanie wyjaśniać symetrię danych. Jeśli wynik testu jest pozytywny, można uznać, że model jest wystarczająco dobry i można go użyć do prognozowania. W przeciwnym razie konieczne może być dostosowanie modelu, aby lepiej opisywał dane.

TEST SYMETRII	
e($y - y^*$)	Liczba reszt dodatnich
-2 972,2	6
20 323,9	Liczba próby
-39 569,4	12
28 927,9	Wartość statystyczna
16 688,4	0
-35 222,4	Rozkład jest idealnie symetryczny
-1 803,2	
-21 928,1	
3 343,6	
21 501,8	
8 204,9	
-2 399,1	

$$=MODUŁ.LICZBY(E221/E224-0,5)/PIERWIASTEK((E221/E224*(1-E221/E224)/(E224-1)))$$

Liczba reszt dodatnich równa jest liczbie reszt ujemnych zatem wynik naszego działania jest równy zero. Stwierdzamy zatem, że rozkład jest symetryczny.

Variance Inflation Factor

Korzystając z utworzonej tabel przeprowadziliśmy również test sprawdzający współliniowość zmiennych. Obliczyliśmy to za pomocą dwóch metod, z których korzystaliśmy na zajęciach. Wynik, który wzięliśmy pod uwagę to wartość obliczona pierwszym sposobem. Zatem w przypadku, gdy VIF osiąga wartość mniejszą od 4, można założyć brak współliniowości predyktorów w modelu.

VIF					Statystyki regresji				
X1	X2	X4	X6	X8	Wielokrotnie	R kwadrat	Dopasowanie	Błąd stand.	Obserwacji
Średnia 0,22430368	5 Średnia Błąd standar	6,1741667 0,2623595	Średnia Błąd stand.	18,5533333 0,91094551	Średnia Błąd stand.	0,31416667 0,01305341	Średnia Błąd stand.	6,105 0,2037136	
Mediana 4,835	Mediana 5,17	6,13 Tryb #N/D	Mediana Tryb #N/D	17,14 Odchylenie s 0,90884	Mediana Tryb #N/D	0,31 0,32	Mediana Tryb #N/D	5,725 1,7056847	
Odchylenie s 0,7770106	Odchylenie s 0,90884	Odchylenie s 3,1556078	Odchylenie s 0,04521833	Odchylenie s 0,79877578	Odchylenie s 0,04521833	Odchylenie s 0,79877578	Odchylenie s 0,4979909	0,725625 0,7056847	
Wariancja 0,6037455	Wariancja pr 0,8259902	Wariancja 9,95786063	Wariancja 0,0020447	Wariancja 0,4979909	Wariancja 0,0020447	Wariancja 0,4979909	Wariancja 0,4979909		
Kurtosza -1,4629971	Kurtosza 0,2974201	Kurtosza -1,2648567	Kurtosza 0,38249661	Kurtosza -0,725625	Kurtosza 0,38249661	Kurtosza -0,725625	Kurtosza -0,725625		
Skośność 0,2443903	Skośność 0,2382934	Skośność 0,59459906	Skośność 0,79877578	Skośność 0,9080485	Skośność 0,79877578	Skośność 0,9080485	Skośność 0,9080485		
Zakres 2,31	Zakres 3,22	Zakres 8,84	Zakres 0,15	Zakres 2	Zakres 8,84	Zakres 0,15	Zakres 2		
Minimum 3,86	Minimum 4,56	Minimum 15,05	Minimum 0,26	Minimum 5,47	Minimum 15,05	Minimum 0,26	Minimum 5,47		
Maksymu 6,17	Maksymum 7,78	Maksymu 23,89	Maksymu 0,41	Maksymu 7,47	Maksymu 23,89	Maksymu 0,41	Maksymu 7,47		
Suma 60	Suma 74,09	Suma 222,64	Suma 3,77	Suma 73,26	Suma 222,64	Suma 3,77	Suma 73,26		
Licznik 12	Licznik 12	Licznik 12	Licznik 12	Licznik 12	Licznik 12	Licznik 12	Licznik 12		
VIF					ANALIZA WARIANCJI				
1. MET.		2,4653191			df	SS	MS	F	Istotność F
2. MET.	X1	5,7369808			Regresja	5	24,20683	4,8413662	1,75832941 0,255387
	X2	8,29364			Resztka	6	16,51984	2,75330594	
	X4	13,286703			Razem	11	40,72667		
	X6	0,1368988							
	X8	3,9689349							

Test Goldfelda – Quandta

Test Goldfelda-Quandta jest jednym z testów heteroskedastyczności, który polega na sprawdzeniu, czy wahania w odpowiedzi są stałe dla wszystkich wartości zmiennych objaśniających. W przypadku heteroskedastyczności, czyli niestabilności wariancji, wahania odpowiedzi nie są stałe i zależą od wartości zmiennych objaśniających. Test Goldfelda-Quandta polega na porównaniu wartości statystyki GQ z kryterium kwantylowym dla odpowiedniego rozkładu. Jeśli wartość statystyki jest istotna na poziomie ufności, oznacza to, że występuje heteroskedastyczność. W takim przypadku nie należy stosować metod opartych na założeniu stałej wariancji, ponieważ wyniki byłyby niepoprawne. Wnioski z testu Goldfelda-Quandta są ważne dla badania heteroskedastyczności, ponieważ niestabilność wariancji może prowadzić do niepoprawnych wniosków i błędów w estymacji parametrów. W przypadku stwierdzenia heteroskedastyczności, może być konieczne zastosowanie innej metody, takiej jak transformacja danych lub modelowanie wariancji.

TEST GOLDFELDA - QUANDTA				
e(y*)	e^*2	e1	e2	e1^*2
-2 972,2	8 833 919,4	-2 972,2	-1 803,2	8 833 919,4
20 323,9	413 062 498,8	20 323,9	-21 928,1	413 062 498,8
-39 569,4	1 565 734 417,2	-39 569,4	3 343,6	1 565 734 417,2
28 927,9	836 821 245,1	28 927,9	21 501,8	836 821 245,1
16 688,4	278 501 143,4	16 688,4	8 204,9	278 501 143,4
-35 222,4	1 240 615 739,0	-35 222,4	-2 399,1	1 240 615 739,0
-1 803,2	3 251 425,9			67 319 592,9
-21 928,1	480 840 420,2			67 319 592,9
3 343,6	11 179 453,7			67 319 592,9
21 501,8	462 325 646,4			67 319 592,9
8 204,9	67 319 592,9			67 319 592,9
-2 399,1	5 755 449,5			67 319 592,9
suma e1^*2				
suma e2^*2				
liczba obserwacji 1szej proby				
liczba obserwacji 2giej proby				
liczba zmiennych				
wariancja 1.				
wariancja 2.				
f(w2/w1)				
wartosc krytyczna				
Nie występuje heteroskedastyczność				

Na podstawie uzyskanych wyników możemy stwierdzić, że w naszym przypadku nie występuje heteroskedastyczność.

Test Shapiro Wilka

Do przeprowadzenia testu Shapiro Wilka mumimy najpierw posortować dane, a następnie obliczyć potrzebne parametry. Następnie obliczamy statystykę W, do której policzyliśmy wcześniej licznik oraz mianownik tego właśnie ilorazu. Do kolejnego kroku potrzebujemy dwóch tabel, które zostały zamieszczone obok. Z pierwszej z nich uzyskujemy wartości zawarte w kolumnie ai, natomiast z drugiej możemy odczytać wartość W dla alfy równej 0,05 oraz W równego 12. Porównując obie wartości W, możemy zauważyc, że ta obliczona poprzez działania na danych z utworzonej przez nas tabeli jest mniejsza od tej, którą odczytaliśmy z tablic. Możemy zatem odrzucić hipotezę zerową.

TEST SHAPIRO WILKA															
t	e(y*) ⁿ	sort	U	xi	xn-i+1	xn-i-1-xi	ai	e-sred							
1	-2 972,2	-39 569,4	-0,121158	-39 569,4	28 979,7	68 497,2	0,5475	-39 160							
2	20 932,9	-35 222,4	0,9798661	-35 222,4	21 501,8	56 724,1	0,3325	-34 813							
3	-39 569,4	-21 928,1	-1.8508173	-21 928,1	20 329,9	42 252,0	0,2347	-21 519							
4	28 972,9	-2 972,2	1.3865056	-2 972,2	16 688,4	16 660,5	0,1586	-2 563							
5	16 688,4	-2 399,1	0,8080407	-2 399,1	8 204,9	10 603,9	0,0922	-1 990							
6	-35 222,4	-1 803,2	-1.6453695	-1 803,2	3 343,6	5 146,7	0,0303	-1 394							
7	-1 803,2	3 343,6	-0,6595076					3 752							
8	-21 928,1	8 204,9	-1,0170529					8 613							
9	3 343,6	16 688,4	0,1773981					17 097							
10	21 501,8	20 329,9	1.0355324					20 732							
11	8 204,9	21 501,8	0,4070946					21 910							
12	-2 399,1	28 979,7	-0,0940702					29 356							
								SUMA							
								5 372 256 940							
SREDNIA ODCZ. ST. SRED. U															
-408,7															
21158,601															
4.51028E-17															

<i>n</i>	2	3	4	5	6	7	8	9	10	11	12	13	14
a1	0.7071	0.7071	0.6872	0.6646	0.6431	0.6233	0.6032	0.5888	0.5799	0.5601	0.5475	0.5359	0.5251
a2			0.1677	0.2413	0.2806	0.3031	0.3164	0.3244	0.3291	0.3315	0.3325	0.3325	0.3318
a3				0.0875	0.1401	0.1743	0.1975	0.2141	0.2260	0.2347	0.2412	0.2460	
a4					0.0561	0.0947	0.1224	0.1429	0.1588	0.1707	0.1822	0.1939	0.2046
a5						0.0399	0.0695	0.0955	0.1212	0.1399	0.1522	0.1699	0.1840
a6							0.0268	0.0539	0.0737	0.0908	0.1077	0.1245	
a7													0.0240

<i>n/p</i>	0.01	0.02	0.05	0.1
3	0.753	0.756	0.767	0.789
4	0.687	0.707	0.748	0.792
5	0.686	0.715	0.762	0.806
6	0.713	0.743	0.788	0.826
7	0.730	0.760	0.803	0.838
8	0.749	0.776	0.818	0.851
9	0.764	0.791	0.829	0.859
10	0.781	0.806	0.842	0.869
11	0.792	0.817	0.850	0.876
12	0.805	0.828	0.859	0.883

Test Jarque – Bera

Przeprowadzamy teraz test Jarque – Bera. Obliczamy kolejne potęgi e, a następnie liczymy potrzebne wartości. Na ich podstawie stwierdzamy, że składniki losowe modelu mają rozkład normalny.

TEST JARQUE-BERA				
e(y^n)	e^2	e^3	e^4	
-2.972,2	8 833 919,4	-26 256 095 820,8		78 038 131 953 731,7
20 323,9	413 062 498,8	8 395 057 051 643,7		170 620 627 893 916 000,0
-39 569,4	1 565 734 417,2	-61 955 112 113 005,6		2 451 524 265 333 750 000,0
28 927,9	836 821 245,1	20 247 450 150 293,8		700 268 796 230 411 000,0
16 688,4	278 501 143,4	4 647 725 537 165,7		77 562 886 848 058 500,0
-35 222,4	1 240 613 739,0	-43 97 433 466 121,6		1 539 127 411 883 040 000,0
-1 803,2	3 251 425,9	-5 862 877 033,7		10 571 770 194 420,7
-21 928,1	480 840 420,2	-10 543 904 217 449,3		231 207 509 739 859 000,0
3 343,6	11 179 453,7	37 379 274 948,6		124 980 185 252 133,0
21 501,8	462 325 646,4	9 940 814 697 000,4		213 745 003 341 947 000,0
8 204,9	67 319 592,9	552 347 282 297,6		4 531 927 587 926 390 000,0
-2 399,1	5 755 449,5	-13 807 621 530,8		33 125 199 250 629,5
SUMY	5 374 240 951,5	-68 461 602 397 612,0		5 388 836 134 145 560 000,0

SUMA (E ⁴) ²	29 039 554 988 449 500 000 000 000 000 000 000,0
n	12
kurtoza	-0,543630832
skośność	-0,625398788
w	-2,35753E-24
k	1,85066E-28
JB	4,5
chi ²	5,991464547

Badanie koincydencji

Test autokorelacji reszt jest testem stosowanym w statystyce, który służy do sprawdzenia, czy reszty regresji są autokorelowane. Autokorelacja oznacza, że wartości pomiaru są skorelowane z wcześniejszymi wartościami tego samego pomiaru. Test autokorelacji reszt jest ważnym krokiem w procesie budowania modelu regresji, ponieważ pozwala zidentyfikować, czy model jest właściwie skonstruowany i czy jego wyniki są wiarygodne. W naszym przypadku po sprawdzeniu elementów z tabel, trzy z nich mają ten sam znak.

Badanie koincydencji					
Y	X1	X2	X4	X6	X8
102,6	3,86	4,56	15,05	0,27	5,47
104,3	4,32	5,18	16,91	0,26	5,56
103,7	5,80	6,50	19,95	0,41	5,59
100,9	5,72	6,35	17,23	0,32	5,70
100,0	5,17	6,15	17,05	0,29	5,75
99,1	4,45	5,72	15,15	0,3	5,57
99,4	4,36	5,58	16,19	0,26	5,52
102,0	4,46	6,00	22,85	0,35	6,09
101,6	4,50	6,11	23,89	0,32	6,64
102,3	5,17	6,56	21,00	0,3	6,86
103,4	6,17	7,78	19,17	0,32	7,04
105,1	6,02	7,60	22,20	0,37	7,47

Współczynniki	
Przecięcie	85,494648
X1	3,2464271
X2	-4,802096
X4	-0,129587
X6	20,342141
X8	4,2537158

Y	1
X1	0,382462
X2	0,354814
X4	0,313465
X6	0,428733
X8	0,486797

ZNAKI X1, X6 I X8 SIĘ ZGADZAJĄ
KIERUNEK ZALEŻNOŚCI MIĘDZY ZMIENNAJĄCEM OBJAŚNIĄCĄ I ZMIENNĄM OBJAŚNIĄCYMI X1, X6 I X8 ZGODNIE Z ZALEŻNOŚCIĄ WYNIKAJĄCĄ Z DANYCH EMPIRYCZNYCH

Test autokorelacji reszt

Ostatnim już testem jest test autokorelacji reszt. Wprowadzamy kolumnę zawierającą wartości e oraz tworzymy taką samą, z tą różnicą, że przesuwamy elementy o jeden dalej. Obliczamy następnie różnice między tymi dwoma wartościami. Musimy teraz sprawdzić ich sumy oraz obliczyć statystykę DW. Następnie korzystając z tabeli wklejonej poniżej, odczytujemy wartości du oraz dl. Ostatnim już krokiem jest sprawdzenie warunków przyjęcia bądź odrzucenia postawionej hipotezy. Trzeci przypadek pokazuje jak zachowują się uzyskane w naszym przypadku liczby. Niestety test nie rozstrzyga autokorelacji w obszarze niekonkluzywności.

TEST AUTOKORELACJI RESZT		
e(y_i^*)	E-1	ROZNICE
-2 972,2		SUMA KWADRATOW ROZNIC
20 323,9	-2 972,2	23 296,1
-39 569,4	20 323,9	-59 893,3
28 927,9	-39 569,4	68 497,2
16 688,4	28 927,9	-12 239,5
-35 222,4	16 688,4	-51 910,7
-1 803,2	-35 222,4	33 419,2
-21 928,1	-1 803,2	-20 124,9
3 343,6	-21 928,1	25 271,6
21 501,8	3 343,6	18 158,2
8 204,9	21 501,8	-13 296,9
-2 399,1	8 204,9	-10 603,9
		-2 399,1

N	k=1	k=2	k=3	k=4	k=5
	d _U				
6	0,61018	1,40015			
7	0,69955	1,36635	0,46723	1,89636	
8	0,76290	1,33238	0,55907	1,77711	0,36744
9	0,82429	1,31988	0,62910	1,69526	0,45476
10	0,87913	1,31971	0,68915	1,64134	0,52534
11	0,92733	1,32409	0,75798	1,60439	0,59477
12	0,97076	1,33137	0,81221	1,57935	0,65765
13	1,00973	1,34040	0,86124	1,56212	0,71465
14	1,04495	1,36027	0,90544	1,55066	0,76666
15	1,07697	1,36064	0,94554	1,54318	0,81396
16	1,10617	1,37092	0,98204	1,53860	0,85718
17	1,13295	1,38122	1,01643	1,53614	0,89675
18	1,15759	1,39133	1,04607	1,53525	0,93310

- Hipoteza H_0 jest odrzucana jeżeli zachodzi nierówność $d < d_U$ i stwierdzamy istnienie istotnej dodatniej autokorelacji.
- zachodzenie nierówności $d_U < d < 4 - d_U$ test nie rozstrzyga kwestii autokorelacji gdyż jesteśmy w tzw. obszarze niekonkluzywności
- Gdy zachodzi nierówność $d_U < d < 4 - d_U$ nie mamy podstaw do odrzucenia hipotezy zerowej
- W przypadku $4 - d_U < d < 4 - d_U$ test nie rozstrzyga kwestii autokorelacji gdyż jesteśmy w tzw. obszarze niekonkluzywności
- Gdy zachodzi $d > 4 - d_U$ stwierdzamy istnienie istotnej ujemnej autokorelacji

4 - $d_U < d < 4 - d_U$
TEST NIE ROZSTRZYGA KWESTII AUTOKORELACJI (JESTEŚMY W OBSZARZE NIEKONKLUZYWNOSCI)